

CLUSTERIZAÇÃO K-MEANS

TRABALHO PRÁTICO 2
INTELIGÊNCIA ARTIFICIAL

Maria Eduarda Ferreira da Silva
Vitória Christie Amaral Santos

OBJETIVOS DO PROJETO

01

IMPLEMENTAR O ALGORITMO K-MEANS DO ZERO EM PYTHON.

02

APLICAR O ALGORITMO NA BASE DE DADOS IRIS, DESCONSIDERANDO AS CLASSES ORIGINAIS.

03

AVALIAR A QUALIDADE DOS CLUSTERS PARA K=3 E K=5 UTILIZANDO O SILHOUETTE SCORE.

04


COMPARAR OS RESULTADOS COM A IMPLEMENTAÇÃO DA BIBLIOTECA SCIKIT-LEARN.

05

UTILIZAR A TÉCNICA DE PCA PARA REDUZIR A DIMENSIONALIDADE E VISUALIZAR OS CLUSTERS.

O QUE É O K - MEANS?

Algoritmo de aprendizado não supervisionado para clusterização de dados.



01

OBJETIVO

Agrupar dados em 'k' clusters com base na similaridade.

02

PROCESSO ITERATIVO

- Associa cada ponto ao centróide (centro do cluster) mais próximo.
- Recalcula o centróide como a média dos pontos do cluster.

IMPLEMENTAÇÃO HARDCORE

Desenvolvido em Python utilizando NumPy para cálculos matemáticos.

Critério de Parada: Convergência dos centróides (quando não há mais mudanças).



FUNÇÕES PRINCIPAIS

01

inicializar_centroides

Escolha aleatória de 'k' pontos iniciais.

02


atribuir_clusters

Cálculo da distância Euclidiana para associação.

01

atualizar_centroides

Cálculo da média para novos centróides.



RESULTADOS

Métrica de Avaliação: Silhouette Score
(quanto mais perto de 1, melhor).


Resultado da implementação Hardcore para K=3:

Silhouette Score: 0.5528

Resultado da implementação Hardcore para K=5:



Silhouette Score: 0.4922

Conclusão: k=3 apresentou a melhor
formação de clusters para a base Iris.





VISUALIZAÇÃO COM PCA


- A base Iris possui 4 dimensões (features), impossibilitando a visualização direta.
- Usamos PCA para reduzir os dados para 2 dimensões, preservando o máximo de informação.



COMPARAÇÃO COM SCIKIT-LEARN



COMPARAÇÃO COM SCIKIT-LEARN



CONCLUSÕES

- A implementação do K-means do zero foi bem-sucedida e produziu resultados consistentes.
- O Silhouette Score foi eficaz para determinar o número ideal de clusters.
- O PCA provou ser uma ferramenta indispensável para a visualização e interpretação de dados multidimensionais.
- A comparação de desempenho ressaltou a importância das otimizações em bibliotecas padrão.



LINK DA APRESENTAÇÃO

<https://youtu.be/YTNUruuPM48>

